

Escuela Técnica Superior de Ingeniería
Informática

Asignatura:

Algebra Lineal y Numérica

Autor:

Fernando José Mateos Gómez

Ultima Modificacion: **9 de febrero de 2022**

၃။ နာဇာနည် ဂျော်ဇော မျှော်မျှော်စွာ ဂျော်ဇော ဂျော်ဇော
 ၃။ ဂျော်ဇော ဂျော်ဇော ဂျော်ဇော ဂျော်ဇော ဂျော်ဇော

Indice

1. Tema 1: Sistemas de Ecuaciones Lineales, Métodos Directos	3
1.1. Sistema de Ecuaciones Lineales	3
1.1.1. Método de Eliminación de Gauss	3
1.1.2. Discusión	3
1.2. Matrices Elementales	4
1.2.1. Propiedades	4
1.3. Método de Gauss-Jordan	4
1.3.1. Matriz Inversa	4
1.4. Método LU	4
1.4.1. Método de Cholesky	5
2. Tema 2: Sistemas de Ecuaciones Lineales y Métodos Iterativos	6
2.1. Introducción	6
2.2. Radio Espectral	6
2.3. Descomposición	6
2.3.1. Método de Jacobi	7
2.3.2. Método de Gauss-Seidel	7
3. Tema 3: Condicionamiento de Sistemas de Ecuaciones Lineales	8
3.1. Introducción	8
3.2. Espacio Vectorial	8
3.2.1. Ejemplos	8
3.3. Normas Vectoriales y Matriciales	8
3.3.1. Vectores	8
3.3.2. Matrices	9
3.4. Número de Condición de una Matriz	9
3.5. Transformaciones y Condicionamiento	10
3.6. Transformaciones Householder	10
3.7. Método QR	11
4. Tema 4: Variedades Lineales y Ortogonalidad	13
4.1. Conceptos Básicos	13
4.1.1. Base de un Espacio Vectorial	13
4.1.2. Cambio de Base	14
4.2. Variedad Lineal	14
4.2.1. Ecuaciones de Base	15
4.3. Operaciones entre Espacios	16
4.4. Producto Escalar	16
4.4.1. Ortogonalidad	16
4.5. Ortonormalidad	17
4.5.1. Ortonormalidad de Gram-Schmidt	17
4.5.2. Variedad Ortogonal	17

5. Tema 5: Aplicaciones Lineales y Diagonalización	18
5.1. Aplicación Lineal	18
5.1.1. Expresión Matricial	18
5.1.2. Operaciones	18
5.1.3. Cambio de Base	19
5.2. Imagen de una Variedad Lineal	19
5.2.1. Imagen Inversa	19
6. Tema 6: Problema de Mínimos Cuadrados	20
6.1. Pseudosolución de un Sistema Incompatible	20
6.2. Transformaciones	20
6.2.1. Pseudosolución	20
6.3. Recta de Regresión	20

1. Tema 1: Sistemas de Ecuaciones Lineales, Métodos Directos

1.1. Sistema de Ecuaciones Lineales

Considerando que un sistema de ecuaciones lineales se puede representar como $\mathbf{Ax} = \mathbf{b}$ podemos decir entonces que esta expresión equivale a:

$$\begin{cases} ax + by + cz + \dots = k \\ \dots + \dots + \dots + \dots = \dots \\ \dots + \dots + \dots + \dots = \dots \\ \dots + \dots + \dots + \dots = \dots \end{cases}$$

Que es lo mismo que:

$$\begin{pmatrix} ax & by & cz & \dots \\ \vdots & \ddots & \dots & \dots \\ \vdots & \dots & \ddots & \dots \\ \vdots & \dots & \dots & \ddots \end{pmatrix} \begin{pmatrix} x \\ y \\ z \\ \vdots \end{pmatrix} = \begin{pmatrix} k \\ \vdots \\ \vdots \\ \vdots \end{pmatrix}$$

1.1.1. Método de Eliminación de Gauss

Aplicando transformaciones elementales simplificamos la matriz $(A|b)$ de forma que sea triangular superior:

$$\begin{pmatrix} 1 & 2 & | 3 \\ -1 & 1 & | 3 \\ 1 & 1 & | 3 \end{pmatrix} \xrightarrow{F_{21}(1) \ F_{31}(-1)} \begin{pmatrix} 1 & 2 & | 3 \\ 0 & 3 & | 6 \\ 0 & -1 & | 0 \end{pmatrix} \xrightarrow{F_{32}(\frac{1}{3}) \ F_2(\frac{1}{3})} \begin{pmatrix} 1 & 2 & | 3 \\ 0 & 1 & | 2 \\ 0 & 0 & | 2 \end{pmatrix}$$
$$\begin{cases} x + 2y = 3 \\ 3y = 6 \\ 0 = 2 \end{cases}$$

En este caso no tiene solución.

1.1.2. Discusión

Existen 3 tipos de sistemas de ecuaciones:

- Incompatible: No tiene soluciones.
- Compatible:
 - Determinado: Tiene una sola solución.
 - Indeterminado: Tiene infinitas soluciones.

Para determinar cual es, sin resolverla, aplicamos el método de Rouché-Fröbenius:

Si el $\text{Rango}(A) \neq \text{Rango}(A|b)$ entonces es Incompatible.

Si el $\text{Rango}(A)$ es igual al número de incógnitas, es Determinado.

Si el $\text{Rango}(A)$ es menor al número de incógnitas es Indeterminado.

1.2. Matrices Elementales

Llamamos a estas a las matrices que surgen de operar con sus filas (F) o columnas C .

- $F_{ij} \Rightarrow F_i \leftrightarrow F_j$
- $F_i(\lambda) \Rightarrow F_i \leftarrow \lambda F_i$
- $F_{ij}(\lambda) \Rightarrow F_i \leftarrow F_i + F_j \lambda$

1.2.1. Propiedades

1. Mover dos filas o columnas implica en multiplicar la matriz por (-1) .
2. Multiplicar una fila o columna por un número, implica multiplicar la matriz por ese valor.
3. $F_{ij} = F_{ij}^{-1}$
4. $F_i^{-1}(\lambda) = F_i(\frac{1}{\lambda})$
5. $F_{ij}^{-1}(\lambda) = F_{ij}(-\lambda)$

1.3. Método de Gauss-Jordan

Se basa en el método de Gauss, partiendo de una matriz I , unitaria, debemos de encontrar otra tal que su producto nos devuelva la solución que buscamos.

1.3.1. Matriz Inversa

Para calcularla debemos de hacer transformaciones elementales de la matriz $A|I$ tal que A se convierta en I , haciendo transformaciones elementales para obtener una matriz triangular superior y luego diagonal. Es decir:

$$A^{-1} = FI$$

1.4. Método LU

Para poder aplicar este algoritmo, y sus derivados, debemos de cerciorarnos que A es una matriz definida positiva, cada una de sus submatrices, partiendo desde el elemento en la primera columna, primera fila, y de ahí expandiendo, es positiva.

$$Ax = b \quad A = LU$$

Considerando A como la matriz con la que partimos, las matrices L y U son matrices diagonales inferior y superior, respectivamente. Considerando esto, podemos usar el método de Gauss para obtener la matriz U y para L , aplicamos el siguiente sistema de ecuaciones:

$$\begin{cases} Ly = b \\ Ux = y_0 \end{cases}$$

Siendo x la solución del sistema. ¿Cómo hayar L ? A partir de las transformaciones elementales que hemos hecho, le hacemos la inversa, y se las aplicamos a una matriz unitaria,

veamos este ejemplo:

$$\begin{pmatrix} 2 & -1 & 0 & 1 \\ 2 & -2 & 0 & 2 \\ -2 & 0 & 1 & -2 \\ -1 & 1 & 0 & 0 \end{pmatrix} \xrightarrow{F_{21}(-1) \ F_{31}(1) \ F_{41}(\frac{1}{2})} \begin{pmatrix} 2 & -1 & 0 & 1 \\ 0 & -1 & 0 & 1 \\ 0 & -1 & 1 & -1 \\ 0 & \frac{1}{2} & 0 & \frac{1}{2} \end{pmatrix} \xrightarrow{F_{32}(-1) \ F_{42}(\frac{1}{2})} \begin{pmatrix} 2 & -1 & 0 & 1 \\ 0 & -1 & 0 & 1 \\ 0 & 0 & 1 & -2 \\ 0 & 0 & 0 & 1 \end{pmatrix}$$

Ahora tenemos la siguiente ecuación:

$$F_{42}\left(\frac{1}{2}\right) F_{32}(-1) F_{41}\left(\frac{1}{2}\right) F_{31}(1) F_{21}(-1) A = U$$

$$L = (F_{42}\left(\frac{1}{2}\right) F_{32}(-1) F_{41}\left(\frac{1}{2}\right) F_{31}(1) F_{21}(-1))^{-1}$$

$$L = F_{21}(1) F_{31}(-1) F_{41}\left(\frac{-1}{2}\right) F_{32}(1) F_{42}\left(\frac{-1}{2}\right) I$$

Con todo esto, ya seríamos capaces de plantear los sistemas de ecuaciones.

1.4.1. Método de Cholesky

Es una derivación del método LU, solo se puede usar cuando la matriz es simétrica $A = A^t$, en cuyo caso $A = K K^t$

De esta forma, ahora la ecuación que tendremos que resolver es la siguiente:

$$\begin{cases} Ky = b \\ K^t x = y_0 \end{cases}$$

Para obtener K debemos de obtener L y multiplicarla por una matriz formada por los elementos de la diagonal de U , con su raíz cuadrada:

$$\begin{pmatrix} 4 & 2 & 0 \\ 2 & 3 & -2 \\ 0 & -2 & 3 \end{pmatrix} \xrightarrow{F_{21}(\frac{-1}{2}) \ F_{32}(1)} \begin{pmatrix} 4 & 2 & 0 \\ 0 & 2 & -2 \\ 0 & 0 & 1 \end{pmatrix} = U$$

$$L = \begin{pmatrix} 1 & 0 & 0 \\ \frac{1}{2} & 1 & 0 \\ 0 & -1 & 1 \end{pmatrix}$$

$$K = \begin{pmatrix} 1 & 0 & 0 \\ \frac{1}{2} & 1 & 0 \\ 0 & -1 & 1 \end{pmatrix} \begin{pmatrix} 2 & 0 & 0 \\ 0 & \sqrt{2} & 0 \\ 0 & 0 & 1 \end{pmatrix} = \begin{pmatrix} 2 & 0 & 0 \\ 1 & \sqrt{2} & 0 \\ 0 & -\sqrt{2} & 1 \end{pmatrix}$$

2. Tema 2: Sistemas de Ecuaciones Lineales y Métodos Iterativos

2.1. Introducción

Dado un sistema $Ax = b$, si A es invertible, es decir, el sistema es compatible determinado, por lo que podemos calcular la solución como $\hat{x} = A^{-1}b$, siendo \hat{x} la única solución posible. Usamos este método cuando el sistema es pequeño, pero si la matriz A es extremadamente grande, podemos usar métodos de aproximación que nos ayuden a acercarnos a la solución, con un error muy cercano a 0.

Para lograr esto usaremos el radio espectral y el autovalor.

2.2. Radio Espectral

Consideramos Q como una matriz cuadrada, por lo que un **autovalor** es un escalar λ para el que existe un vector x no nulo tal que:

$$Qx = \lambda x$$

Tras esto podemos calcular los autovalores como:

$$|Q - \lambda I| = 0$$

De esta forma solo tendremos que calcular un determinante para esta matriz resultante tal que sus raíces son sus autovalores:

$$p_Q(\lambda) = |Q - \lambda I|$$

Así obtendremos el radio espectral, que será el autovalor de mayor valor, absoluto:

$$\rho(\lambda) = \{|\lambda| : \lambda \text{ autovalor de } Q\}$$

2.3. Descomposición

¿Cómo calculamos la matriz Q ?, simple, cualquier matriz cuadrada se puede descomponer en la suma de dos matrices (una de ellas es invertible):

$$A = M + N \quad Ax = b$$

$$(M + N)x = b$$

$$Mx = b - Nx$$

$$x = M^{-1}b + M^{-1}Nx = C + Qx$$

De esta forma, de forma general podemos obtener la solución en la iteración enésima:

$$\hat{x}_n = Qx_{n-1} + C$$

Podemos calcular el error con Q^n , cuanto más cercana a cero sea esa matriz, entonces más precisa es la solución.

Es decir, calculamos el radio espectral de:

$$\rho(-M^{-1}N) = 0$$

Ahora, considerando que las matrices M y N , las podemos seguir descomponiendo, podemos descomponer A en 3 matrices (triangular superior e inferior y la diagonal)

$$A = D + U + L$$

2.3.1. Método de Jacobi

$$\boxed{\hat{x}_n = Jx_{n-1} + C} \quad J = -D^{-1}(L + U) \quad C = D^{-1}b$$

2.3.2. Método de Gauss-Seidel

$$\boxed{\hat{x}_n = \text{GS}x_{n-1} + C} \quad \text{GS} = -(D + L)^{-1}U \quad C = (D + L)^{-1}b$$

3. Tema 3: Condicionamiento de Sistemas de Ecuaciones Lineales

3.1. Introducción

En la realidad, los valores de nuestro sistema no son conocidos o exactos, lo que afecta a nuestro sistema, para esto condicionaremos el sistema (para obtener un error muy bajo). Cuando peor condicionado esté el sistema, más grande será el error.

3.2. Espacio Vectorial

Sobre un cuerpo \mathbb{K} (\mathbb{R} o \mathbb{C}), es un cuerpo \mathcal{V} que tiene dos operaciones (suma y producto). Siendo $(u, v \in \mathcal{V})$, podemos usar estas propiedades:

- Suma:
 - Propiedad Conmutativa
 - Propiedad Asociativa
- Producto:
 - $(\alpha, \beta)(v + u) = \alpha v + \alpha u + \beta v + \beta u$
 - $(\alpha\beta)u = u(\alpha\beta)$

3.2.1. Ejemplos

Por parte de los vectores, se pueden escribir así:

$$\mathbb{R}^n = \{n(u_1, \dots, u_n) : u_1, \dots, u_n \in \mathbb{R}\}$$

Por parte de las matrices:

$$\mathcal{M}_n(\mathbb{R}) = \{A_{(aij)} \text{ matrices cuadradas de orden } n \text{ con } a_{ij} \in \mathbb{R}\}$$

3.3. Normas Vectoriales y Matriciales

3.3.1. Vectores

Es un **espacio vectorial** \mathcal{V} sobre \mathbb{R} tal que $\|\cdot\| : \mathcal{V} \rightarrow [0, \infty)$ cumple:

- $\|u\| = 0 \Leftrightarrow u = 0$
- Propiedad homogénea: $\|\lambda u\| = |\lambda| \|u\|$
- $\|u + v\| \leq \|u\| + \|v\|$

De esta forma podemos calcular también la distancia entre dos vectores:

$$d(u, v) = \|u - v\|$$

Es un **espacio normado**, un espacio vectorial \mathcal{V} dotado de una forma:

- $\|u\|_\infty = \max\{|u_1|, \dots, |u_n|\}$
- $\|u\|_k = \sqrt[k]{\sum_{n=1}^k u_n^k}$
- Norma euclídea: $\|u\|_2 = \sqrt{\sum_{n=1}^2 u_n^2}$

3.3.2. Matrices

Una **norma matricial**, se define en un espacio de matrices, normas sobre $\mathcal{M}_n(\mathbb{R})$ que cumplen:

- $\|AB\| \leq \|A\| \|B\|$
- Norma matricial con la vectorial: $\|Au\| \leq \|A\| \|u\|$

Ejemplos de normas son:

- $\|A\| = \max_{u \neq 0} \frac{\|Au\|}{\|u\|}$
- La máxima suma de las **columnas** $\|A\|_\infty = \max \sum_{j=1} |a_{ij}|$
- La máxima suma de las **filas** $\|A\|_1 = \max \sum_{i=1} |a_{ij}|$
- Norma espectral: $\|A\|_2 = \sqrt{\rho(A^t A)}$
- Norma de Frobenius, es la suma de todos los elementos de la matriz, al cuadrado:
 $\sqrt{\sum_{i=1} \sum_{j=1} a_{ij}^2}$.

O la suma de los elementos de la matriz traspuesta por si misma: $\sqrt{\delta(A^t, A)}$

Es similar a la norma espectral.

3.4. Número de Condición de una Matriz

Dado un sistema $Ax = b$, con A invertible y $b \neq 0$, b se modificará por b_p :

$$\begin{cases} Ax = b & x_0 = A^{-1}b \\ Ax_p = b_p & x_p = A^{-1}b_p \end{cases}$$

La solución de x_p tendrá un error, $\mathbf{C} = \|b - b_p\|$, que llamaremos **error absoluto**.

Si:

$$\varepsilon \simeq 0 \Rightarrow \|x_0 - x_p\| = \|A^{-1}(b - b_p)\| \leq \|A^{-1}\| \|b - b_p\|$$

Esto significa que nos interesa que $\|A^{-1}\|$ sea lo más pequeño posible, ya que $\|b - b_p\|$ será muy pequeño

Por otro lado:

$$\|b\| \leq \|Ax_0\| \Rightarrow \|x_0\| \leq \frac{\|b\|}{\|A\|}$$

Entonces, el error relativo cumple lo siguiente:

$$\boxed{\frac{\|x_0 - x_p\|}{\|x_0\|} \leq \|A\| \|A^{-1}\| \frac{\|b - b_p\|}{\|b\|} < \lambda} \quad \boxed{\text{cond}(A) \varepsilon < \lambda}$$

Considerando λ el error total, y ε el error de precisión, solo tendremos que tomar la precisión del error de precisión como:

$$\varepsilon > \frac{\|b - b_p\|}{\|b\|}$$

Podemos concluir que lo que indica si el error es grande o no es el condicionamiento de A , cuanto menor sea este valor, menor el error.

Si ε no sobrepasa el valor λ , diremos que el sistema está bien condicionado. [Ejemplo: $\lambda = 10^{-3} \rightarrow \varepsilon = 10^{-4}$]

En definitiva:

$$\text{cond}(A) \frac{\mathbf{C}}{\|b_0\|} < \lambda \quad ; \quad \varepsilon > \frac{\mathbf{C}}{\|b_0\|}$$

3.5. Transformaciones y Condicionamiento

Sigue siendo laborioso tantos cálculos, por ende usaremos estas propiedades para simplificar las tareas:

- $\text{cond}(A) \geq 1$ pero cuanto más cerca a 1 esté, mejor condicionado.
- si tenemos dos sistemas

$$\begin{cases} Ax = b \\ Bx = c \end{cases}$$

El que tenga un condicionamiento más cercano a 1, será mejor.

- Llamamos λ_{\min} y λ_{\max} a los autovalores de $A^t A$ de mayor y menor módulo, por lo que tenemos:

$$\text{cond}_2(A) = \|A\|_2 \|A^{-1}\|_2 = \sqrt{\frac{\lambda_{\max}}{\lambda_{\min}}}$$

- Llamamos a λ_n a los autovalores de $A^t A$, por lo que tenemos:

$$\text{cond}_F(A) = \|A\|_F \|A^{-1}\|_F = \sqrt{\sum_{i=1} \lambda_i \sum_{i=1} \frac{1}{\lambda_i}}$$

Para lograr una transformación eficiente, debemos de encontrar una matriz U tal que cumpla dos propiedades:

- $\text{cond}(UA) \leq \text{cond}(A)$
- La matriz U debe de ser unitaria, ortogonal:
 - $U^{-1} = U^t$
 - $U^t U = I$
 - $\text{cond}(UA)_2 = \text{cond}(A)_2$
 - $\text{cond}(UA)_F = \text{cond}(A)_F$

3.6. Transformaciones Householder

Dado un vector $v \in \mathbb{R}^n$, se define la transformación Householder asociada a v :

$$H_v = I - \frac{2}{v^t v} v v^t$$

De forma que:

$$v = \begin{pmatrix} v_1 \\ \vdots \\ v_n \end{pmatrix}$$

Así, podemos calcular los dos productos de una forma bastante eficiente:

$$v v^t = \begin{pmatrix} v_1^2 & v_1 v_2 & \cdots & v_1 v_n \\ v_2 v_1 & v_2^2 & \cdots & v_2 v_n \\ \vdots & \vdots & \ddots & \vdots \\ v_n v_1 & v_n v_2 & \cdots & v_n^2 \end{pmatrix} \quad v^t v = \|v\|_2^2 = \sum_{i=1} v_i^2$$

3.7. Método QR

Para lograr obtener v debemos de obtener dos vectores u y w que tendrán que tener la misma norma euclídea, y repetiremos el proceso tantas veces como filas tenga A

$$(A|b) = \left(\begin{array}{cccc|c} 1 & -3 & -2 & 3 & 2 \\ 1 & 0 & 3 & 2 & 2 \\ 1 & -4 & 4 & 1 & 2 \\ -1 & 3 & 1 & -4 & 0 \end{array} \right)$$

El vector u_1 se corresponderá con la columna 1 de la matriz A y w_1 con un vector del mismo tamaño que u_1 con todos los valores a 0, excepto su posición 1.

En caso de trabajar con la iteración enésima, u_n será el vector enésimo de la anterior transformación y w_n un vector con todos los valores a cero, salvo el de la posición enésima, todos los valores anteriores a esta posición tendrán el mismo valor que el del vector u_n .

$$u_1 = \begin{pmatrix} 1 \\ 1 \\ 1 \\ -1 \end{pmatrix} \quad w_1 = \begin{pmatrix} \|u_1\|^2 \\ 0 \\ 0 \\ 0 \end{pmatrix} \quad \|u_1\|^2 = 2$$

$$v_1 = u_1 - w_1 = \begin{pmatrix} -1 \\ 1 \\ 1 \\ -1 \end{pmatrix}$$

$$H_{v_1} = \begin{pmatrix} 1 & 1 & 1 & 1 \\ 1 & 1 & 1 & 1 \\ 1 & 1 & 1 & 1 \\ 1 & 1 & 1 & 1 \end{pmatrix} - \frac{2}{4} \begin{pmatrix} 1 & -1 & -1 & 1 \\ -1 & 1 & 1 & -1 \\ -1 & 1 & 1 & -1 \\ 1 & -1 & -1 & 1 \end{pmatrix} \quad H_{v_1}(A|b) = \left(\begin{array}{cccc|c} 2 & -5 & 2 & 5 & 1 \\ 0 & 2 & -1 & 0 & -1 \\ 0 & -2 & 0 & -1 & -1 \\ 0 & 1 & 5 & -2 & 3 \end{array} \right)$$

Ahora que tenemos la primera iteración hacemos las siguientes:

$$u_2 = \begin{pmatrix} -5 \\ 2 \\ -2 \\ 1 \end{pmatrix} \quad w_2 = \begin{pmatrix} -5 \\ \|u_2\|^2 \\ 0 \\ 0 \end{pmatrix} \quad \|u_2\|^2 = 3$$

$$v_2 = u_2 - w_2 = \begin{pmatrix} 0 \\ -1 \\ -2 \\ 1 \end{pmatrix}$$

$$H_{v_2}(A|b) = \left(\begin{array}{cccc|c} 2 & -5 & 2 & 5 & 1 \\ 0 & 3 & 1 & 0 & 1 \\ 0 & 0 & 4 & -1 & 3 \\ 0 & 0 & 3 & -2 & 1 \end{array} \right)$$

Ahora la ultima:

$$u_3 = \begin{pmatrix} 2 \\ 1 \\ 4 \\ 3 \end{pmatrix} \quad w_3 = \begin{pmatrix} 2 \\ 1 \\ \|u_3\|^2 \\ 0 \end{pmatrix} \quad \|u_3\|^2 = 5$$

$$v_3 = u_3 - w_3 = \begin{pmatrix} 0 \\ 0 \\ -1 \\ 3 \end{pmatrix}$$

$$H_{v_3}(A|b) = \left(\begin{array}{cccc|c} 2 & -5 & 2 & 5 & 1 \\ 0 & 3 & 1 & 0 & 1 \\ 0 & 0 & 5 & -2 & 3 \\ 0 & 0 & 0 & 1 & 1 \end{array} \right)$$

Ya solo tendremos que resolver el sistema resultante usando Gauss

4. Tema 4: Variedades Lineales y Ortogonalidad

4.1. Conceptos Básicos

4.1.1. Base de un Espacio Vectorial

Sea \mathcal{V} un espacio vectorial sobre \mathbb{R} ($\mathcal{V} = \mathbb{R}^n$) y $(v_1, \dots, v_n) \in \mathcal{V}$, denotaremos:

1. Una combinación lineal (CL) de (v_1, \dots, v_n) a cualquier expresión tal que:

$$\sum_{i=1} \alpha_i v_i \quad \text{Con } \alpha_i \in \mathbb{R}$$

2. (v_1, \dots, v_n) son linealmente independientes (LI) si:

$$\sum_{i=1} \alpha_i v_i = 0$$

3. (v_1, \dots, v_n) son linealmente dependientes (LD) si no son **CL** del resto, es decir si $\exists u, v \in \mathcal{V} \ v = \alpha u$, es decir si ambos vectores son proporcionales entre si. $\{v_1, \dots, v_n\}$ es un sistema generador (Sg), de \mathcal{V} si cualquier vector de \mathcal{V} se puede expresar como **CL** de $\{v_1, \dots, v_n\}$

4. Llamamos base de un espacio vectorial \mathcal{V} a cualquier conjunto de vectores $\mathcal{B} = \{v_1, \dots, v_n\}$ que sean **Sg** y **LI** (Como dato a tener en cuenta, mientras no nos digan lo contrario, trabajaremos sobre la **base canónica** $\mathbf{C} = \{e_1, e_2, \dots, e_n\}$) que tendrán una estructura como esta:

$$e_1 = \begin{pmatrix} 1 \\ 0 \\ \vdots \\ \vdots \end{pmatrix} \quad e_2 = \begin{pmatrix} 0 \\ 1 \\ \vdots \\ \vdots \end{pmatrix} \quad \cdots \quad e_n = \begin{pmatrix} 0 \\ 0 \\ \vdots \\ 1 \end{pmatrix}$$

5. Todas las bases de \mathcal{V} tienen el mismo número de vectores, se denomina dimensión $\dim(\mathcal{V})$

Por esto, $\forall u \in \mathcal{V}$, existe una forma de expresarlo como **CL** de los vectores de la base en la que se encuentra:

$$\mathcal{B} = \{v_1, \dots, v_n\} \Rightarrow u = \sum_{n=1}^k \alpha_n v_n = \sum_{n=1}^k \beta_n v_n$$

6. A los coeficientes, (α, β) , se les llama coordenadas de u respecto de \mathcal{B} , se escriben los vectores entonces así:

$$u = v_1(\alpha_1, \dots, \alpha_n), \dots, v_n(\beta_1, \dots, \beta_n)_{\mathcal{B}}$$

Por ejemplo:

$$\mathcal{B} = \{v_1(2, 5), v_2(1, -1)\} \quad u = (4, 3)$$
$$\begin{pmatrix} 4 \\ 3 \end{pmatrix} = \alpha_1 \begin{pmatrix} 2 \\ 5 \end{pmatrix} + \alpha_2 \begin{pmatrix} 1 \\ -1 \end{pmatrix} \Rightarrow \begin{cases} u = (1, 2)_{\mathcal{B}} \\ u = (4, 3)_{\mathbf{C}} \end{cases}$$

Para terminar vamos a hablar de las bases.

Partiendo de la definición de espacio vectorial, dada anteriormente y $w, u \in \mathcal{V}$ de los que conocemos sus coordenadas en base \mathcal{B} vemos:

$$w_{\mathcal{B}} = \sum_{i=1}^k \alpha_i u_{i\mathcal{B}} \Leftrightarrow \begin{pmatrix} u_{1\mathcal{B}} & \cdots & u_{k\mathcal{B}} \end{pmatrix} \begin{pmatrix} \alpha_1 \\ \vdots \\ \alpha_k \end{pmatrix} = w_{\mathcal{B}}$$

De esta forma w es **CL** de u solamente si el sistema de ecuaciones con el que trabajemos, $Ax = b$, es compatible.

$\Rightarrow (u_1, \dots, u_n)$ son **LI** si y solo si, el rango de nuestra matriz A es igual al tamaño de este vector u : $\text{Rango}(A) = n$ y $|A| \neq 0$

$\Rightarrow \{u_1, \dots, u_n\}$ es base de \mathcal{V} , por lo que $\dim(\mathcal{V}) = n$ y el vector u tiene todas sus componentes **LI**, si se aplica cualquier transformación elemental por filas.

4.1.2. Cambio de Base

Supongamos que tenemos dos bases \mathcal{B} y \mathcal{D} , de un espacio vectorial \mathcal{V} y un vector genérico v , digamos que para expresar el vector v en base \mathcal{B} a la base \mathcal{D} :

$$\boxed{v_{\mathcal{D}} = \begin{pmatrix} u_{1\mathcal{D}} & \cdots & u_{n\mathcal{D}} \end{pmatrix} \begin{pmatrix} v_{1\mathcal{B}} \\ \vdots \\ v_{n\mathcal{B}} \end{pmatrix}} \quad \boxed{v_{\mathcal{B}} = \begin{pmatrix} u_{1\mathcal{D}} & \cdots & u_{n\mathcal{D}} \end{pmatrix}^{-1} \begin{pmatrix} v_{1\mathcal{D}} \\ \vdots \\ v_{n\mathcal{D}} \end{pmatrix}}$$

Solo podremos hacer esto cuando las dos bases con las que trabajemos, se encuentren en el mismo espacio vectorial.

Ejemplo:

$$\mathcal{B} = \{v_1, v_2, v_3, v_4\} \quad \mathcal{D} = \{u_1, u_2, u_3, u_4\} \in \mathbf{R}^4 \Rightarrow \begin{cases} u_1 = 3v_1 - 2v_3 + v_4 \\ u_2 = -v_1 + v_2 - v_4 \\ u_3 = v_1 - 2v_2 + v_3 + 2v_4 \\ u_4 = v_2 - v_3 \end{cases}$$

Podemos sacar la siguiente ecuación de la base \mathcal{D} respecto de \mathcal{B} :

$$\mathcal{D} = \{(3, 0, -2, 1)_{\mathcal{B}}, (-1, 1, 0, -1)_{\mathcal{B}}, (1, -2, 1, 2)_{\mathcal{B}}, (0, 1, -1, 0)_{\mathcal{B}}\}$$

Ahora, aplicando la definición:

$$v_{\mathcal{B}} = B_{\mathcal{B}} v_{\mathcal{D}} \quad v_{\mathcal{D}} = B_{\mathcal{B}}^{-1} v_{\mathcal{B}}$$

4.2. Variedad Lineal

Considerando un conjunto de vectores $v \in \mathcal{V}$, llamamos **variedad lineal generada** por los vectores de v al conjunto de **CL** posibles de dichos vectores, se denota por $L = \mathcal{L} \langle v_1, \dots, v_n \rangle$. Es decir:

$$\mathcal{L} \langle v_1, \dots, v_n \rangle = \left\{ \sum_{i=1}^n \alpha_i v_i : \alpha_1, \dots, \alpha_n \in \mathbf{R}^n \right\}$$

Propiedades:

- L es un subespacio vectorial de \mathcal{V} .
- El conjunto de vectores v es un **Sg** de L .
- Si eliminamos los vectores **LI** de v , obtenemos una base de L .
- Si L contiene a un solo vector, trabajamos con una recta; si tiene 2, con un plano; si tiene 3 con un espacio tridimensional, etc
- $0 \leq \dim(L) \leq \dim(\mathcal{V})$, por lo tanto:
 - $\dim(L) = 0 \Leftrightarrow L = \{\emptyset\}$
 - $\dim(L) = \dim(\mathcal{V}) \Leftrightarrow L = \mathcal{V}$

4.2.1. Ecuaciones de Base

Existen distintas formas de representar los vectores de una base \mathcal{B} en una variedad lineal L :

1. **Ecuación Vectorial:** $x_{\mathcal{B}} = \sum_{i=1}^n \alpha_i v_{i\mathcal{B}}$
2. **Ecuación Paramétrica:** Es el sistema de ecuaciones que obtenemos.
3. **Ecuaciones Implícitas:** Expresandose como un sistema de ecuaciones o imponiendo que el número de ecuaciones sea igual a $\dim(\mathcal{V}) = \dim(L)$, es decir, $\text{Rango}(u_{1\mathcal{B}} | \dots | u_{n\mathcal{B}}) = \text{Rango}(u_{1\mathcal{B}} | \dots | u_{n\mathcal{B}}|_{x_{\mathcal{B}}})$

$$\begin{pmatrix} x \\ y \\ z \end{pmatrix} = \alpha_1 \begin{pmatrix} 1 \\ 0 \\ -2 \end{pmatrix} + \alpha_2 \begin{pmatrix} 0 \\ -1 \\ 3 \end{pmatrix} \rightarrow_{1,2} \begin{cases} x = \alpha_1 \\ y = \alpha_2 \\ z = 3\alpha_2 - 2\alpha_1 \end{cases} \rightarrow_{2,3} 2x + 3y + z = 0$$

Ejemplo:

$$\mathcal{B} = \{v_1, \dots, v_5\} \quad L = \mathcal{L}\langle u_1, \dots, u_4 \rangle$$

$$\begin{cases} u_1 = v_1 - v_2 + 2v_3 + v_4 \\ u_2 = v_2 - 2v_3 + v_4 + 2v_5 \\ u_3 = v_2 + 6v_3 + 3v_4 - 4v_5 \\ u_4 = -v_1 + 2v_2 + v_4 - v_5 \end{cases} \Rightarrow \begin{cases} u_1(1, -1, 2, 1, 0) \\ u_2(0, 1, -2, 1, 2) \\ u_3(0, 1, 6, 3, -4) \\ u_4(-1, 2, 0, 1, -1) \end{cases}$$

Si queremos obtener una base de L en B , debemos sacar las ecuaciones implícitas de L en base B , por lo que el rango entre los vectores de L y los de $L \cup \{x_{\mathcal{B}}\}$ deben de ser iguales:

$$\left(\begin{array}{cccc|c} 1 & 0 & 0 & -1 & x_1 \\ -1 & 1 & 1 & 2 & x_2 \\ 2 & -2 & 6 & 0 & x_3 \\ 1 & 1 & 3 & 1 & x_4 \\ 0 & 2 & -4 & -1 & x_5 \end{array} \right) \xrightarrow[\text{Usando Gauss}]{\text{Hacemos transformaciones elementales}} \left(\begin{array}{cccc|c} 1 & 0 & 0 & -1 & x_1 \\ 0 & 1 & 1 & 1 & x_1 + x_2 \\ 0 & 0 & 2 & 1 & -2x_1 - x_2 + x_4 \\ 0 & 0 & 0 & 0 & 8x_1 + 6x_2 + x_3 - 4x_4 \\ 0 & 0 & 0 & 0 & -8x_1 - 5x_2 - 3x_4 + x_5 \end{array} \right)$$

Vemos que el rango de L es 3, por lo que para que el rango de la matriz ampliada se iguale, obtenemos las ecuaciones de L en base \mathcal{B} :

$$\begin{cases} 8x_1 + 6x_2 + x_3 - 4x_4 = 0 \\ -8x_1 - 5x_2 - 3x_4 + x_5 = 0 \end{cases}$$

Por otro lado debemos de convertir la matriz escalonada que obtuvimos antes, a una diagonal unitaria, para así obtener una base de L , y como sabemos que el rango debe de ser 3, solo tendrá 3 variables esta base:

$$\begin{pmatrix} 1 & 0 & 0 & -1 \\ 0 & 1 & 0 & \frac{1}{2} \\ 0 & 0 & 1 & \frac{1}{2} \\ 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 \end{pmatrix} \equiv \left\{ \hat{u}_1, \hat{u}_2, \hat{u}_3, -\hat{u}_1 + \frac{1}{2}(\hat{u}_2 + \hat{u}_3) \right\}$$

4.3. Operaciones entre Espacios

- Intersección $L_1 \cap L_2$: Obtenemos las ecuaciones implícitas de ambos espacios (juntando)
- Suma $L_1 + L_2 \Rightarrow \mathcal{L} \langle v_1, \dots, w_1, \dots \rangle$: Juntamos los dos espacios y sacamos los vectores **LI**.
- Suma Directa $L_1 \oplus L_2 = L_1 + L_2 \Leftrightarrow L_1 \cap L_2 = \{\emptyset\}$: Si la suma nos da como resultado el mismo espacio vectorial sobre el que trabajamos, \mathcal{V} entonces, ambos espacios contienen variables complementarias.

4.4. Producto Escalar

Lo denotamos como $\langle u, w \rangle \in \mathcal{V}$, con $u_{\mathcal{B}}$ y $w_{\mathcal{B}}$ siendo vectores no nulos. Por definición el producto escalar es:

$$\langle u, w \rangle = \|u\|_2 \|w\|_2 \cos \sigma$$

Sin embargo, esta es la definición que nos sirve al estudiar la ortogonalidad, de forma general funciona de una forma distinta:

$$\langle u, w \rangle = (u_1 \quad \dots \quad u_n)_{\mathcal{B}} Q \begin{pmatrix} w_1 \\ \vdots \\ w_n \end{pmatrix}_{\mathcal{B}}$$

¿Qué es esta matriz Q ? Es una matriz compuesta por todas las combinaciones posibles entre los vectores que conforman la base con la que trabajamos, de forma que sus valores son el producto escalar entre 2 vectores cualquiera de esa base:

$$Q = \begin{pmatrix} \langle v_1, v_1 \rangle & \dots & \langle v_1, v_n \rangle \\ \vdots & \ddots & \vdots \\ \dots & \dots & \langle v_n, v_n \rangle \end{pmatrix}$$

Aquí $v \in \mathcal{B}$. Por lo tanto podemos describir el producto escalar de la siguiente forma:

$$\langle u, w \rangle = u^t Q w = \sum_{i=1}^n \sum_{j=1}^n u_i w_j \langle v_i, v_j \rangle$$

4.4.1. Ortogonalidad

Decimos que dos vectores son ortogonales cuando su producto escalar es cero, son perpendiculares. **También sabemos que el producto escalar es conmutativo** y

4.5. Ortonormalidad

Decimos que tenemos una base ortonormal cuando:

- El producto escalar de un vector por si mismo vale 1
- El producto escalar por el resto de combinaciones de vectores, vale cero, es decir, son ortonales.

4.5.1. Ortonormalidad de Gram-Schmidt

Para obtener un conjunto de vectores ortonormales debemos de obtener una base ortonormal, y para esto aplicaremos el algoritmo de Gram-Schmidt:

$$w_k = u_k - \sum_{n=1}^{k-1} w_n \frac{\langle u_k, w_n \rangle}{\langle w_n, w_n \rangle}$$

Siendo u_k el vector que conforma un espacio concreto y w_k vectores ortogonales entre si, de forma que para que sean ortonormales, crearemos un espacio tal que:

$$v = \left(\frac{w_1}{\|w_1\|}, \dots, \frac{w_k}{\|w_k\|} \right)$$

4.5.2. Variedad Ortogonal

Denotamos a aquellas variedades, tal que el producto escalar entre los vectores de dos bases, da siempre cero.

5. Tema 5: Aplicaciones Lineales y Diagonalización

5.1. Aplicación Lineal

Llamamos a una aplicación f entre dos espacios vectoriales \mathcal{V} , y \mathcal{W} es una regla que asigna a cada elemento de x de \mathcal{V} un elemento $f(x)$ de \mathcal{W} . Normalmente se escribe así $f : \mathcal{V} \rightarrow \mathcal{W}$. Llamaremos imagen de x por f a $f(x)$, siendo el argumento la **preimagen**.

Para que f sea una aplicación lineal u **homomorfismo** si:

- $f(u + v) = f(u) + f(v) \quad \forall u, v \in \mathcal{V}$
- $f(\alpha u) = \alpha f(u) \quad \forall \alpha \in \mathbb{R}, u \in \mathcal{V}$
- Además, si cumple estas dos propiedades $f(0) = 0$

Terminamos diciendo, que toda aplicación lineal sobre su mismo espacio $f : \mathcal{V} \rightarrow \mathcal{V}$, se le llama **endomorfismo**. Veamos un ejemplo de aplicación lineal:

$$f : \mathbb{R}^2 \rightarrow \mathbb{R}^2 \quad f(x, y) = (x^2, x + y)$$

$$f(u+v) = f(u)+f(v) = f(x+x')+f(y+y') = (2x+2x', x+y+x'+y') = (2x, x+y)+(2x', x'+y')$$

$$f(\alpha u) = \alpha f(u) = f(\alpha x, \alpha y) = (2\alpha x, \alpha x + \alpha y) = \alpha(2x, x + y)$$

$f(x, y)$ Es un endomorfismo

5.1.1. Expresión Matricial

Para manejar las aplicaciones de forma sencilla, obtendremos una expresión matricial en base a la base del espacio del que partimos y del que deseamos llegar. A grosso modo, tomamos las coordenadas en base \mathcal{B} de un vector genérico y hallamos su imagen usando las dos propiedades anteriores, y finalmente a este vector, le multiplicamos una matriz con las coordenadas en base \mathcal{D} en la otra base:

$$f(X)_{\mathcal{D}} = A_{\mathcal{D}} X_{\mathcal{B}} = (f(v_1)_{\mathcal{D}} \quad \cdots \quad f(v_n)_{\mathcal{D}}) \begin{pmatrix} x_1 \\ \vdots \\ x_n \end{pmatrix}_{\mathcal{B}}$$

Ejemplo:

$$\begin{aligned} \mathcal{B} &= \{v_1, v_2, v_3\} \in \mathbb{R}^3 \quad \mathcal{D} = \{w_1, w_2\} \in \mathbb{R}^2 \\ \begin{cases} f(v_1) = 2w_1 - w_2 \\ f(v_2) = w_1 + 4w_2 \\ f(v_3) = -3w_1 + 2w_2 \end{cases} & \begin{cases} f(v_1) = (2, -1)_{\mathcal{D}} \\ f(v_2) = (1, 4)_{\mathcal{D}} \\ f(v_3) = (-3, 2)_{\mathcal{D}} \end{cases} \\ f(X)_{\mathcal{D}} = A = \begin{pmatrix} 2 & 1 & -3 \\ -1 & 4 & 2 \end{pmatrix} X_{\mathcal{B}} = \begin{pmatrix} -3 \\ 1 \\ -2 \end{pmatrix} & \Rightarrow f(u) = w_1 + 3w_2 \end{aligned}$$

5.1.2. Operaciones

Si $f(X)$ la podemos denotar por $M_f X$ entonces podemos realizar algunas operaciones sobre f :

- *Multiplicar por un escalar:* $\alpha f(X) = \alpha M_f X$
- *Multiplicar f con otra aplicación lineal:* $f(X) + g(X) = (M_f + M_g)X$
- *Composición de otra aplicación lineal con f :* $h(f(x)) = M_h M_f X$

5.1.3. Cambio de Base

Consideremos dos nuevas bases \mathcal{E} y \mathcal{F} de los espacios \mathcal{V} y \mathcal{W} respectivamente, pertenecientes a la aplicación $f : \mathcal{V} \rightarrow \mathcal{W}$ en las bases \mathcal{B} y \mathcal{C} $f(X)_C = A_C X_B$, Para hayar las matrices de cambio de base de $\mathcal{B} \rightarrow \mathcal{E}$ y $\mathcal{C} \rightarrow \mathcal{F}$:

$$\left. \begin{array}{l} X_{\mathcal{E}} = P_{\mathcal{E}} X_{\mathcal{B}} \\ X_{\mathcal{F}} = Q_{\mathcal{F}} X_{\mathcal{C}} \end{array} \right\} \Rightarrow f(X)_{\mathcal{F}} = Q_{\mathcal{F}} f(X)_{\mathcal{C}} = Q_{\mathcal{F}} A_{\mathcal{C}} X_{\mathcal{B}} = Q_{\mathcal{F}} A_{\mathcal{C}} P_{\mathcal{E}}^{-1} X_{\mathcal{E}}$$

5.2. Imagen de una Variedad Lineal

Sea $f : \mathcal{V} \rightarrow \mathcal{W}$ una aplicación lineal de la matriz A en las bases \mathcal{B} y \mathcal{C} , y L una variedad lineal de \mathcal{V} . La imagen de L por f se define como:

$$f(L) = \{f(v) : v \in L\}$$

Se llama **imagen de f** a $\text{Im}f = f(\mathcal{V})$:

- $L = \mathcal{L}\langle u_1, \dots, u_k \rangle \Rightarrow f(L) = \mathcal{L}\langle f(u_1), \dots, f(u_k) \rangle$
- $\dim(\text{Im}f) = \text{Rango}(A)$
- Si la aplicación es sobreyectiva, $\forall w \in \mathcal{W}$ tiene preimagen y no la tendrá si $f(\mathcal{V}) \neq \mathcal{W}$, entonces $\text{Im}f = \mathcal{W}$

5.2.1. Imagen Inversa

La imagen inversa de L se define como:

$$f^{-1}(L) = \{v \in \mathcal{V} : f(v) \in L\}$$

Siendo f una aplicación lineal de matriz A en las bases \mathcal{B} y \mathcal{C} Y se le llama **kernel** de f a $\ker f = f^{-1}(0)$. Para sacarla debemos de tener en cuenta ciertos detalles:

- $x \in f^{-1}(L) \Leftrightarrow f(x) \in L \Leftrightarrow Mf(X)_C \Leftrightarrow MAX_B = 0$
- $\ker f \equiv AX_B = 0$ y $\dim(\ker f) = \dim(\mathcal{V}) - \text{Rango}(A)$
- Si f es inyectiva el kernel de la función está vacío.

De los cuales llegamos a la siguiente conclusión:

$$L \equiv MX_C \rightarrow f^{-1}(L) = MAX_B = 0$$

6. Tema 6: Problema de Mínimos Cuadrados

6.1. Pseudosolución de un Sistema Incompatible

Este problema se conoce como **problema de mínimos cuadrados**, y se usa cuando tenemos un sistema de ecuaciones tal que no existe solución, de forma que buscamos un \hat{x} que se aproxime a lo que deseamos:

$$\boxed{\hat{x} = (A^t A)^{-1} A^t b} \quad \boxed{\varepsilon = \|b - A\hat{x}\|_2} \quad \text{Error de aproximación}$$

6.2. Transformaciones

6.2.1. Pseudosolución

Podemos aplicar Householder para calcular pseudosoluciones de estos sistemas, usando el mismo algoritmo.

El error viene denotado por la *norma euclídea* de la pseudopsolución.

6.3. Recta de Regresión

Dado un conjunto de puntos $P_1(x_1, y_1), \dots, P_n(x_n, y_n)$ buscamos la recta que mejor se adecúe a estos puntos, para esto calculamos la pseudosolución de $A \binom{m}{n} b$ que equivale a:

$$\boxed{\begin{pmatrix} x_1 & 1 \\ \vdots & 1 \\ x_n & 1 \end{pmatrix} \begin{pmatrix} m \\ n \end{pmatrix} = \begin{pmatrix} y_1 \\ \vdots \\ y_n \end{pmatrix}}$$