

Escuela Técnica Superior de Ingeniería  
Informática

Asignatura:

Algebra Lineal y Numérica

Autor:

*Fernando José Mateos Gómez*

Ultima Modificacion: **6 de febrero de 2022**

၃။ နာဇာနည် ဂျော်ဇော မျှော်မျှော်စွာ ဂျော်ဇော ဂျော်ဇော  
 ၃။ ဂျော်ဇော ဂျော်ဇော ဂျော်ဇော ဂျော်ဇော ဂျော်ဇော

# Indice

<b>1. Tema 1: Sistemas de Ecuaciones Lineales, Métodos Directos</b>	<b>3</b>
1.1. Sistema de Ecuaciones Lineales . . . . .	3
1.1.1. Método de Eliminación de Gauss . . . . .	3
1.1.2. Discusión . . . . .	3
1.2. Matrices Elementales . . . . .	4
1.2.1. Propiedades . . . . .	4
1.3. Método de Gauss-Jordan . . . . .	4
1.3.1. Matriz Inversa . . . . .	4
1.4. Método LU . . . . .	4
1.4.1. Método de Cholesky . . . . .	5
<b>2. Tema 2: Sistemas de Ecuaciones Lineales y Métodos Iterativos</b>	<b>6</b>
2.1. Introducción . . . . .	6
2.2. Radio Espectral . . . . .	6
2.3. Descomposición . . . . .	6
2.3.1. Método de Jacobi . . . . .	7
2.3.2. Método de Gauss-Seidel . . . . .	7
<b>3. Tema 3: Condicionamiento de Sistemas de Ecuaciones Lineales</b>	<b>8</b>
3.1. Introducción . . . . .	8
3.2. Espacio Vectorial . . . . .	8
3.2.1. Ejemplos . . . . .	8
3.3. Normas Vectoriales y Matriciales . . . . .	8
3.3.1. Vectores . . . . .	8
3.3.2. Matrices . . . . .	9
3.4. Número de Condición de una Matriz . . . . .	9
3.5. Transformaciones y Condicionamiento . . . . .	10
3.6. Transformaciones Householder . . . . .	10
3.7. Método QR . . . . .	11
<b>4. Tema 4: Variedades Lineales y Ortogonalidad</b>	<b>13</b>
4.1. Conceptos Básicos . . . . .	13
4.1.1. Base de un Espacio Vectorial . . . . .	13
4.1.2. Cambio de Base . . . . .	14
4.2. Variedad Lineal . . . . .	14
4.2.1. Ecuaciones de Base . . . . .	15
4.3. Operaciones entre Espacios . . . . .	16
4.4. Producto Escalar . . . . .	16
4.4.1. Ortogonalidad . . . . .	16
4.5. Ortonormalidad . . . . .	16
4.5.1. Ortonormalidad de Gram-Schmidt . . . . .	16

<b>5. Tema 5: Aplicaciones Lineales y Diagonalización</b>	<b>17</b>
<b>6. Tema 6: Problema de Mínimos Cuadrados</b>	<b>18</b>

# 1. Tema 1: Sistemas de Ecuaciones Lineales, Métodos Directos

## 1.1. Sistema de Ecuaciones Lineales

Considerando que un sistema de ecuaciones lineales se puede representar como  $\mathbf{Ax} = \mathbf{b}$  podemos decir entonces que esta expresión equivale a:

$$\begin{cases} ax + by + cz + \dots = k \\ \dots + \dots + \dots + \dots = \dots \\ \dots + \dots + \dots + \dots = \dots \\ \dots + \dots + \dots + \dots = \dots \end{cases}$$

Que es lo mismo que:

$$\begin{pmatrix} ax & by & cz & \dots \\ \vdots & \ddots & \dots & \dots \\ \vdots & \dots & \ddots & \dots \\ \vdots & \dots & \dots & \ddots \end{pmatrix} \begin{pmatrix} x \\ y \\ z \\ \vdots \end{pmatrix} = \begin{pmatrix} k \\ \vdots \\ \vdots \\ \vdots \end{pmatrix}$$

### 1.1.1. Método de Eliminación de Gauss

Aplicando transformaciones elementales simplificamos la matriz  $(A|b)$  de forma que sea triangular superior:

$$\begin{pmatrix} 1 & 2 & | 3 \\ -1 & 1 & | 3 \\ 1 & 1 & | 3 \end{pmatrix} \xrightarrow{F_{21}(1) \ F_{31}(-1)} \begin{pmatrix} 1 & 2 & | 3 \\ 0 & 3 & | 6 \\ 0 & -1 & | 0 \end{pmatrix} \xrightarrow{F_{32}(\frac{1}{3}) \ F_2(\frac{1}{3})} \begin{pmatrix} 1 & 2 & | 3 \\ 0 & 1 & | 2 \\ 0 & 0 & | 2 \end{pmatrix}$$
$$\begin{cases} x + 2y = 3 \\ 3y = 6 \\ 0 = 2 \end{cases}$$

En este caso no tiene solución.

### 1.1.2. Discusión

Existen 3 tipos de sistemas de ecuaciones:

- Incompatible: No tiene soluciones.
- Compatible:
  - Determinado: Tiene una sola solución.
  - Indeterminado: Tiene infinitas soluciones.

Para determinar cual es, sin resolverla, aplicamos el método de Rouché-Fröbenius:

Si el  $\text{Rango}(A) \neq \text{Rango}(A|b)$  entonces es Incompatible.

Si el  $\text{Rango}(A)$  es igual al número de incógnitas, es Determinado.

Si el  $\text{Rango}(A)$  es menor al número de incógnitas es Indeterminado.

## 1.2. Matrices Elementales

Llamamos a estas a las matrices que surgen de operar con sus filas ( $F$ ) o columnas  $C$ .

- $F_{ij} \Rightarrow F_i \leftrightarrow F_j$
- $F_i(\lambda) \Rightarrow F_i \leftarrow \lambda F_i$
- $F_{ij}(\lambda) \Rightarrow F_i \leftarrow F_i + F_j \lambda$

### 1.2.1. Propiedades

1. Mover dos filas o columnas implica en multiplicar la matriz por  $(-1)$ .
2. Multiplicar una fila o columna por un número, implica multiplicar la matriz por ese valor.
3.  $F_{ij} = F_{ij}^{-1}$
4.  $F_i^{-1}(\lambda) = F_i(\frac{1}{\lambda})$
5.  $F_{ij}^{-1}(\lambda) = F_{ij}(-\lambda)$

## 1.3. Método de Gauss-Jordan

Se basa en el método de Gauss, partiendo de una matriz  $I$ , unitaria, debemos de encontrar otra tal que su producto nos devuelva la solución que buscamos.

### 1.3.1. Matriz Inversa

Para calcularla debemos de hacer transformaciones elementales de la matriz  $A|I$  tal que  $A$  se convierta en  $I$ , haciendo transformaciones elementales para obtener una matriz triangular superior y luego diagonal. Es decir:

$$A^{-1} = FI$$

## 1.4. Método LU

Para poder aplicar este algoritmo, y sus derivados, debemos de cerciorarnos que  $A$  es una matriz definida positiva, cada una de sus submatrices, partiendo desde el elemento en la primera columna, primera fila, y de ahí expandiendo, es positiva.

$$Ax = b \quad A = LU$$

Considerando  $A$  como la matriz con la que partimos, las matrices  $L$  y  $U$  son matrices diagonales inferior y superior, respectivamente. Considerando esto, podemos usar el método de Gauss para obtener la matriz  $U$  y para  $L$ , aplicamos el siguiente sistema de ecuaciones:

$$\begin{cases} Ly = b \\ Ux = y_0 \end{cases}$$

Siendo  $x$  la solución del sistema. ¿Cómo hayar  $L$ ? A partir de las transformaciones elementales que hemos hecho, le hacemos la inversa, y se las aplicamos a una matriz unitaria,

veamos este ejemplo:

$$\begin{pmatrix} 2 & -1 & 0 & 1 \\ 2 & -2 & 0 & 2 \\ -2 & 0 & 1 & -2 \\ -1 & 1 & 0 & 0 \end{pmatrix} \xrightarrow{F_{21}(-1) \ F_{31}(1) \ F_{41}(\frac{1}{2})} \begin{pmatrix} 2 & -1 & 0 & 1 \\ 0 & -1 & 0 & 1 \\ 0 & -1 & 1 & -1 \\ 0 & \frac{1}{2} & 0 & \frac{1}{2} \end{pmatrix} \xrightarrow{F_{32}(-1) \ F_{42}(\frac{1}{2})} \begin{pmatrix} 2 & -1 & 0 & 1 \\ 0 & -1 & 0 & 1 \\ 0 & 0 & 1 & -2 \\ 0 & 0 & 0 & 1 \end{pmatrix}$$

Ahora tenemos la siguiente ecuación:

$$F_{42}\left(\frac{1}{2}\right) F_{32}(-1) F_{41}\left(\frac{1}{2}\right) F_{31}(1) F_{21}(-1) A = U$$

$$L = (F_{42}\left(\frac{1}{2}\right) F_{32}(-1) F_{41}\left(\frac{1}{2}\right) F_{31}(1) F_{21}(-1))^{-1}$$

$$L = F_{21}(1) F_{31}(-1) F_{41}\left(\frac{-1}{2}\right) F_{32}(1) F_{42}\left(\frac{-1}{2}\right) I$$

Con todo esto, ya seríamos capaces de plantear los sistemas de ecuaciones.

#### 1.4.1. Método de Cholesky

Es una derivación del método LU, solo se puede usar cuando la matriz es simétrica  $A = A^t$ , en cuyo caso  $A = K K^t$

De esta forma, ahora la ecuación que tendremos que resolver es la siguiente:

$$\begin{cases} Ky = b \\ K^t x = y_0 \end{cases}$$

Para obtener  $K$  debemos de obtener  $L$  y multiplicarla por una matriz formada por los elementos de la diagonal de  $U$ , con su raíz cuadrada:

$$\begin{pmatrix} 4 & 2 & 0 \\ 2 & 3 & -2 \\ 0 & -2 & 3 \end{pmatrix} \xrightarrow{F_{21}(\frac{-1}{2}) \ F_{32}(1)} \begin{pmatrix} 4 & 2 & 0 \\ 0 & 2 & -2 \\ 0 & 0 & 1 \end{pmatrix} = U$$

$$L = \begin{pmatrix} 1 & 0 & 0 \\ \frac{1}{2} & 1 & 0 \\ 0 & -1 & 1 \end{pmatrix}$$

$$K = \begin{pmatrix} 1 & 0 & 0 \\ \frac{1}{2} & 1 & 0 \\ 0 & -1 & 1 \end{pmatrix} \begin{pmatrix} 2 & 0 & 0 \\ 0 & \sqrt{2} & 0 \\ 0 & 0 & 1 \end{pmatrix} = \begin{pmatrix} 2 & 0 & 0 \\ 1 & \sqrt{2} & 0 \\ 0 & -\sqrt{2} & 1 \end{pmatrix}$$

## 2. Tema 2: Sistemas de Ecuaciones Lineales y Métodos Iterativos

### 2.1. Introducción

Dado un sistema  $Ax = b$ , si  $A$  es invertible, es decir, el sistema es compatible determinado, por lo que podemos calcular la solución como  $\hat{x} = A^{-1}b$ , siendo  $\hat{x}$  la única solución posible. Usamos este método cuando el sistema es pequeño, pero si la matriz  $A$  es extremadamente grande, podemos usar métodos de aproximación que nos ayuden a acercarnos a la solución, con un error muy cercano a 0.

Para lograr esto usaremos el radio espectral y el autovalor.

### 2.2. Radio Espectral

Consideramos  $Q$  como una matriz cuadrada, por lo que un **autovalor** es un escalar  $\lambda$  para el que existe un vector  $x$  no nulo tal que:

$$Qx = \lambda x$$

Tras esto podemos calcular los autovalores como:

$$|Q - \lambda I| = 0$$

De esta forma solo tendremos que calcular un determinante para esta matriz resultante tal que sus raíces son sus autovalores:

$$p_Q(\lambda) = |Q - \lambda I|$$

Así obtendremos el radio espectral, que será el autovalor de mayor valor, absoluto:

$$\rho(\lambda) = \{|\lambda| : \lambda \text{ autovalor de } Q\}$$

### 2.3. Descomposición

¿Cómo calculamos la matriz  $Q$ ?, simple, cualquier matriz cuadrada se puede descomponer en la suma de dos matrices (una de ellas es invertible):

$$A = M + N \quad Ax = b$$

$$(M + N)x = b$$

$$Mx = b - Nx$$

$$x = M^{-1}b + M^{-1}Nx = C + Qx$$

De esta forma, de forma general podemos obtener la solución en la iteración enésima:

$$\hat{x}_n = Qx_{n-1} + C$$

Podemos calcular el error con  $Q^n$ , cuanto más cercana a cero sea esa matriz, entonces más precisa es la solución.

Es decir, calculamos el radio espectral de:

$$\rho(-M^{-1}N) = 0$$

Ahora, considerando que las matrices  $M$  y  $N$ , las podemos seguir descomponiendo, podemos descomponer  $A$  en 3 matrices (triangular superior e inferior y la diagonal)

$$A = D + U + L$$

### 2.3.1. Método de Jacobi

$$\boxed{\hat{x}_n = Jx_{n-1} + C} \quad J = -D^{-1}(L + U) \quad C = D^{-1}b$$

### 2.3.2. Método de Gauss-Seidel

$$\boxed{\hat{x}_n = \text{GS}x_{n-1} + C} \quad \text{GS} = -(D + L)^{-1}U \quad C = (D + L)^{-1}b$$



### 3. Tema 3: Condicionamiento de Sistemas de Ecuaciones Lineales

#### 3.1. Introducción

En la realidad, los valores de nuestro sistema no son conocidos o exactos, lo que afecta a nuestro sistema, para esto condicionaremos el sistema (para obtener un error muy bajo). Cuando peor condicionado esté el sistema, más grande será el error.

#### 3.2. Espacio Vectorial

Sobre un cuerpo  $\mathbb{K}$  ( $\mathbb{R}$  o  $\mathbb{C}$ ), es un cuerpo  $\mathcal{V}$  que tiene dos operaciones (suma y producto). Siendo  $(u, v \in \mathcal{V})$ , podemos usar estas propiedades:

- Suma:
  - Propiedad Conmutativa
  - Propiedad Asociativa
- Producto:
  - $(\alpha, \beta)(v + u) = \alpha v + \alpha u + \beta v + \beta u$
  - $(\alpha\beta)u = u(\alpha\beta)$

##### 3.2.1. Ejemplos

Por parte de los vectores, se pueden escribir así:

$$\mathbb{R}^n = \{n(u_1, \dots, u_n) : u_1, \dots, u_n \in \mathbb{R}\}$$

Por parte de las matrices:

$$\mathcal{M}_n(\mathbb{R}) = \{A_{(aij)} \text{ matrices cuadradas de orden } n \text{ con } a_{ij} \in \mathbb{R}\}$$

#### 3.3. Normas Vectoriales y Matriciales

##### 3.3.1. Vectores

Es un **espacio vectorial**  $\mathcal{V}$  sobre  $\mathbb{R}$  tal que  $\|\cdot\| : \mathcal{V} \rightarrow [0, \infty)$  cumple:

- $\|u\| = 0 \Leftrightarrow u = 0$
- Propiedad homogénea:  $\|\lambda u\| = |\lambda| \|u\|$
- $\|u + v\| \leq \|u\| + \|v\|$

De esta forma podemos calcular también la distancia entre dos vectores:

$$d(u, v) = \|u - v\|$$

Es un **espacio normado**, un espacio vectorial  $\mathcal{V}$  dotado de una forma:

- $\|u\|_\infty = \max\{|u_1|, \dots, |u_n|\}$
- $\|u\|_k = \sqrt[k]{\sum_{n=1}^k u_n^k}$
- Norma euclídea:  $\|u\|_2 = \sqrt{\sum_{n=1}^2 u_n^2}$

### 3.3.2. Matrices

Una **norma matricial**, se define en un espacio de matrices, normas sobre  $\mathcal{M}_n(\mathbb{R})$  que cumplen:

- $\|AB\| \leq \|A\| \|B\|$
- Norma matricial con la vectorial:  $\|Au\| \leq \|A\| \|u\|$

Ejemplos de normas son:

- $\|A\| = \max_{u \neq 0} \frac{\|Au\|}{\|u\|}$
- La máxima suma de las **columnas**  $\|A\|_\infty = \max \sum_{j=1} |a_{ij}|$
- La máxima suma de las **filas**  $\|A\|_1 = \max \sum_{i=1} |a_{ij}|$
- Norma espectral:  $\|A\|_2 = \sqrt{\rho(A^t A)}$
- Norma de Frobenius, es la suma de todos los elementos de la matriz, al cuadrado:  
 $\sqrt{\sum_{i=1} \sum_{j=1} a_{ij}^2}$ .

O la suma de los elementos de la matriz traspuesta por si misma:  $\sqrt{\delta(A^t, A)}$

Es similar a la norma espectral.

### 3.4. Número de Condición de una Matriz

Dado un sistema  $Ax = b$ , con  $A$  invertible y  $b \neq 0$ ,  $b$  se modificará por  $b_p$ :

$$\begin{cases} Ax = b & x_0 = A^{-1}b \\ Ax_p = b_p & x_p = A^{-1}b_p \end{cases}$$

La solución de  $x_p$  tendrá un error,  $\mathbf{C} = \|b - b_p\|$ , que llamaremos **error absoluto**.

Si:

$$\varepsilon \simeq 0 \Rightarrow \|x_0 - x_p\| = \|A^{-1}(b - b_p)\| \leq \|A^{-1}\| \|b - b_p\|$$

Esto significa que nos interesa que  $\|A^{-1}\|$  sea lo más pequeño posible, ya que  $\|b - b_p\|$  será muy pequeño

---

Por otro lado:

$$\|b\| \leq \|Ax_0\| \Rightarrow \|x_0\| \leq \frac{\|b\|}{\|A\|}$$

Entonces, el error relativo cumple lo siguiente:

$$\boxed{\frac{\|x_0 - x_p\|}{\|x_0\|} \leq \|A\| \|A^{-1}\| \frac{\|b - b_p\|}{\|b\|} < \lambda} \quad \boxed{\text{cond}(A) \varepsilon < \lambda}$$

Considerando  $\lambda$  el error total, y  $\varepsilon$  el error de precisión, solo tendremos que tomar la precisión del error de precisión como:

$$\varepsilon > \frac{\|b - b_p\|}{\|b\|}$$

Podemos concluir que lo que indica si el error es grande o no es el condicionamiento de  $A$ , cuanto menor sea este valor, menor el error.

Si  $\varepsilon$  no sobrepasa el valor  $\lambda$ , diremos que el sistema está bien condicionado. [Ejemplo:  $\lambda = 10^{-3} \rightarrow \varepsilon = 10^{-4}$ ]

En definitiva:

$$\text{cond}(A) \frac{\mathbf{C}}{\|b_0\|} < \lambda \quad ; \quad \varepsilon > \frac{\mathbf{C}}{\|b_0\|}$$

### 3.5. Transformaciones y Condicionamiento

Sigue siendo laborioso tantos cálculos, por ende usaremos estas propiedades para simplificar las tareas:

- $\text{cond}(A) \geq 1$  pero cuanto más cerca a 1 esté, mejor condicionado.
- Si tenemos dos sistemas y

$$\begin{cases} Ax = b \\ Bx = c \end{cases}$$

El que tenga un condicionamiento más cercano a 1, será mejor.

- Llamamos  $\lambda_{\min}$  y  $\lambda_{\max}$  a los autovalores de  $A^t A$  de mayor y menor módulo, por lo que tenemos:

$$\text{cond}_2(A) = \|A\|_2 \|A^{-1}\|_2 = \sqrt{\frac{\lambda_{\max}}{\lambda_{\min}}}$$

- Llamamos a  $\lambda_n$  a los autovalores de  $A^t A$ , por lo que tenemos:

$$\text{cond}_F(A) = \|A\|_F \|A^{-1}\|_F = \sqrt{\sum_{i=1} \lambda_i \sum_{i=1} \frac{1}{\lambda_i}}$$

Para lograr una transformación eficiente, debemos de encontrar una matriz  $U$  tal que cumpla dos propiedades:

- $\text{cond}(UA) \leq \text{cond}(A)$
- La matriz  $U$  debe de ser unitaria, ortogonal:
  - $U^{-1} = U^t$
  - $U^t U = I$
  - $\text{cond}(UA)_2 = \text{cond}(A)_2$
  - $\text{cond}(UA)_F = \text{cond}(A)_F$

### 3.6. Transformaciones Householder

Dado un vector  $v \in \mathbb{R}^n$ , se define la transformación Householder asociada a  $v$ :

$$H_v = I - \frac{2}{v^t v} v v^t$$

De forma que:

$$v = \begin{pmatrix} v_1 \\ \vdots \\ v_n \end{pmatrix}$$

Así, podemos calcular los dos productos de una forma bastante eficiente:

$$v v^t = \begin{pmatrix} v_1^2 & v_1 v_2 & \cdots & v_1 v_n \\ v_2 v_1 & v_2^2 & \cdots & v_2 v_n \\ \vdots & \vdots & \ddots & \vdots \\ v_n v_1 & v_n v_2 & \cdots & v_n^2 \end{pmatrix} \quad v^t v = \|v\|_2^2 = \sum_{i=1} v_i^2$$

### 3.7. Método QR

Para lograr obtener  $v$  debemos de obtener dos vectores  $u$  y  $w$  que tendrán que tener la misma norma euclídea, y repetiremos el proceso tantas veces como filas tenga  $A$

$$(A|b) = \left( \begin{array}{cccc|c} 1 & -3 & -2 & 3 & 2 \\ 1 & 0 & 3 & 2 & 2 \\ 1 & -4 & 4 & 1 & 2 \\ -1 & 3 & 1 & -4 & 0 \end{array} \right)$$

El vector  $u_1$  se corresponderá con la columna 1 de la matriz  $A$  y  $w_1$  con un vector del mismo tamaño que  $u_1$  con todos los valores a 0, excepto su posición 1.

En caso de trabajar con la iteración enésima,  $u_n$  será el vector enésimo de la anterior transformación y  $w_n$  un vector con todos los valores a cero, salvo el de la posición enésima, todos los valores anteriores a esta posición tendrán el mismo valor que el del vector  $u_n$ .

$$u_1 = \begin{pmatrix} 1 \\ 1 \\ 1 \\ -1 \end{pmatrix} \quad w_1 = \begin{pmatrix} \|u_1\|^2 \\ 0 \\ 0 \\ 0 \end{pmatrix} \quad \|u_1\|^2 = 2$$

$$v_1 = u_1 - w_1 = \begin{pmatrix} -1 \\ 1 \\ 1 \\ -1 \end{pmatrix}$$

$$H_{v_1} = \begin{pmatrix} 1 & 1 & 1 & 1 \\ 1 & 1 & 1 & 1 \\ 1 & 1 & 1 & 1 \\ 1 & 1 & 1 & 1 \end{pmatrix} - \frac{2}{4} \begin{pmatrix} 1 & -1 & -1 & 1 \\ -1 & 1 & 1 & -1 \\ -1 & 1 & 1 & -1 \\ 1 & -1 & -1 & 1 \end{pmatrix} \quad H_{v_1}(A|b) = \left( \begin{array}{cccc|c} 2 & -5 & 2 & 5 & 1 \\ 0 & 2 & -1 & 0 & -1 \\ 0 & -2 & 0 & -1 & -1 \\ 0 & 1 & 5 & -2 & 3 \end{array} \right)$$

Ahora que tenemos la primera iteración hacemos las siguientes:

$$u_2 = \begin{pmatrix} -5 \\ 2 \\ -2 \\ 1 \end{pmatrix} \quad w_2 = \begin{pmatrix} -5 \\ \|u_2\|^2 \\ 0 \\ 0 \end{pmatrix} \quad \|u_2\|^2 = 3$$

$$v_2 = u_2 - w_2 = \begin{pmatrix} 0 \\ -1 \\ -2 \\ 1 \end{pmatrix}$$

$$H_{v_2}(A|b) = \left( \begin{array}{cccc|c} 2 & -5 & 2 & 5 & 1 \\ 0 & 3 & 1 & 0 & 1 \\ 0 & 0 & 4 & -1 & 3 \\ 0 & 0 & 3 & -2 & 1 \end{array} \right)$$

Ahora la ultima:

$$u_3 = \begin{pmatrix} 2 \\ 1 \\ 4 \\ 3 \end{pmatrix} \quad w_3 = \begin{pmatrix} 2 \\ 1 \\ \|u_3\|^2 \\ 0 \end{pmatrix} \quad \|u_3\|^2 = 5$$

$$v_3 = u_3 - w_3 = \begin{pmatrix} 0 \\ 0 \\ -1 \\ 3 \end{pmatrix}$$

$$H_{v_3}(A|b) = \left( \begin{array}{cccc|c} 2 & -5 & 2 & 5 & 1 \\ 0 & 3 & 1 & 0 & 1 \\ 0 & 0 & 5 & -2 & 3 \\ 0 & 0 & 0 & 1 & 1 \end{array} \right)$$

Ya solo tendremos que resolver el sistema resultante usando Gauss

## 4. Tema 4: Variedades Lineales y Ortogonalidad

### 4.1. Conceptos Básicos

#### 4.1.1. Base de un Espacio Vectorial

Sea  $\mathcal{V}$  un espacio vectorial sobre  $\mathbb{R}$  ( $\mathcal{V} = \mathbb{R}^n$ ) y  $(v_1, \dots, v_n) \in \mathcal{V}$ , denotaremos:

1. Una combinación lineal (CL) de  $(v_1, \dots, v_n)$  a cualquier expresión tal que:

$$\sum_{i=1} \alpha_i v_i \quad \text{Con } \alpha_i \in \mathbb{R}$$

2.  $(v_1, \dots, v_n)$  son linealmente independientes (LI) si:

$$\sum_{i=1} \alpha_i v_i = 0$$

3.  $(v_1, \dots, v_n)$  son linealmente dependientes (LD) si no son **CL** del resto, es decir si  $\exists u, v \in \mathcal{V} \ v = \alpha u$ , es decir si ambos vectores son proporcionales entre si.  $\{v_1, \dots, v_n\}$  es un sistema generador (Sg), de  $\mathcal{V}$  si cualquier vector de  $\mathcal{V}$  se puede expresar como **CL** de  $\{v_1, \dots, v_n\}$

4. Llamamos base de un espacio vectorial  $\mathcal{V}$  a cualquier conjunto de vectores  $\mathcal{B} = \{v_1, \dots, v_n\}$  que sean **Sg** y **LI** (Como dato a tener en cuenta, mientras no nos digan lo contrario, trabajaremos sobre la **base canónica**  $\mathbf{C} = \{e_1, e_2, \dots, e_n\}$ ) que tendrán una estructura como esta:

$$e_1 = \begin{pmatrix} 1 \\ 0 \\ \vdots \\ \vdots \end{pmatrix} \quad e_2 = \begin{pmatrix} 0 \\ 1 \\ \vdots \\ \vdots \end{pmatrix} \quad \cdots \quad e_n = \begin{pmatrix} 0 \\ 0 \\ \vdots \\ 1 \end{pmatrix}$$

5. Todas las bases de  $\mathcal{V}$  tienen el mismo número de vectores, se denomina dimensión  $\dim(\mathcal{V})$

Por esto,  $\forall u \in \mathcal{V}$ , existe una forma de expresarlo como **CL** de los vectores de la base en la que se encuentra:

$$\mathcal{B} = \{v_1, \dots, v_n\} \Rightarrow u = \sum_{n=1}^k \alpha_n v_n = \sum_{n=1}^k \beta_n v_n$$

6. A los coeficientes,  $(\alpha, \beta)$ , se les llama coordenadas de  $u$  respecto de  $\mathcal{B}$ , se escriben los vectores entonces así:

$$u = v_1 (\alpha_1, \dots, \alpha_n), \dots, v_n (\beta_1, \dots, \beta_n)_{\mathcal{B}}$$

Por ejemplo:

$$\begin{aligned} \mathcal{B} &= \{v_1 (2, 5), v_2 (1, -1)\} & u &= (4, 3) \\ \begin{pmatrix} 4 \\ 3 \end{pmatrix} &= \alpha_1 \begin{pmatrix} 2 \\ 5 \end{pmatrix} + \alpha_2 \begin{pmatrix} 1 \\ -1 \end{pmatrix} & \Rightarrow & \begin{cases} u = (1, 2)_{\mathcal{B}} \\ u = (4, 3)_{\mathbf{C}} \end{cases} \end{aligned}$$

Para terminar vamos a hablar de las bases.

Partiendo de la definición de espacio vectorial, dada anteriormente y  $w, u \in \mathcal{V}$  de los que conocemos sus coordenadas en base  $\mathcal{B}$  vemos:

$$w_{\mathcal{B}} = \sum_{i=1}^k \alpha_i u_{i\mathcal{B}} \Leftrightarrow (u_{1\mathcal{B}} \quad \cdots \quad u_{k\mathcal{B}}) \begin{pmatrix} \alpha_1 \\ \vdots \\ \alpha_k \end{pmatrix} = w_{\mathcal{B}}$$

De esta forma  $w$  es **CL** de  $u$  solamente si el sistema de ecuaciones con el que trabajemos,  $Ax = b$ , es compatible.

$\Rightarrow (u_1, \dots, u_n)$  son **LI** si y solo si, el rango de nuestra matriz  $A$  es igual al tamaño de este vector  $u$ :  $\text{Rango}(A) = n$  y  $|A| \neq 0$

$\Rightarrow \{u_1, \dots, u_n\}$  es base de  $\mathcal{V}$ , por lo que  $\dim(\mathcal{V}) = n$  y el vector  $u$  tiene todas sus componentes **LI**, si se aplica cualquier transformación elemental por filas.

#### 4.1.2. Cambio de Base

Supongamos que tenemos dos bases  $\mathcal{B}$  y  $\mathcal{D}$ , de un espacio vectorial  $\mathcal{V}$  y un vector genérico  $v$ , digamos que para expresar el vector  $v$  en base  $\mathcal{B}$  a la base  $\mathcal{D}$ :

$$\boxed{v_{\mathcal{D}} = (u_{1\mathcal{D}} \quad | \cdots | \quad u_{n\mathcal{D}}) \begin{pmatrix} v_{1\mathcal{B}} \\ \vdots \\ v_{n\mathcal{B}} \end{pmatrix}} \quad \boxed{v_{\mathcal{B}} = (u_{1\mathcal{D}} \quad | \cdots | \quad u_{n\mathcal{D}})^{-1} \begin{pmatrix} v_{1\mathcal{D}} \\ \vdots \\ v_{n\mathcal{D}} \end{pmatrix}}$$

Solo podremos hacer esto cuando las dos bases con las que trabajemos, se encuentren en el mismo espacio vectorial.

Ejemplo:

$$\mathcal{B} = \{v_1, v_2, v_3, v_4\} \quad \mathcal{D} = \{u_1, u_2, u_3, u_4\} \in \mathbf{R}^4 \Rightarrow \begin{cases} u_1 = 3v_1 - 2v_2 + v_4 \\ u_2 = -v_1 + v_2 - v_4 \\ u_3 = v_1 - 2v_2 + v_3 + 2v_4 \\ u_4 = v_2 - v_3 \end{cases}$$

Podemos sacar la siguiente ecuación de la base  $\mathcal{D}$  respecto de  $\mathcal{B}$ :

$$\mathcal{D} = \{(3, 0, -2, 1)_{\mathcal{B}}, (-1, 1, 0, -1)_{\mathcal{B}}, (1, -2, 1, 2)_{\mathcal{B}}, (0, 1, -1, 0)_{\mathcal{B}}\}$$

Ahora, aplicando la definición:

$$v_{\mathcal{B}} = B_{\mathcal{B}} v_{\mathcal{D}} \quad v_{\mathcal{D}} = B_{\mathcal{B}}^{-1} v_{\mathcal{B}}$$

#### 4.2. Variedad Lineal

Considerando un conjunto de vectores  $v \in \mathcal{V}$ , llamamos **variedad lineal generada** por los vectores de  $v$  al conjunto de **CL** posibles de dichos vectores, se denota por  $L = \mathcal{L} \langle v_1, \dots, v_n \rangle$ . Es decir:

$$\mathcal{L} \langle v_1, \dots, v_n \rangle = \left\{ \sum_{i=1}^n \alpha_i v_i : \alpha_1, \dots, \alpha_n \in \mathbf{R}^n \right\}$$

Propiedades:

- $L$  es un subespacio vectorial de  $\mathcal{V}$ .
- El conjunto de vectores  $v$  es un **Sg** de  $L$ .
- Si eliminamos los vectores **LI** de  $v$ , obtenemos una base de  $L$ .
- Si  $L$  contiene a un solo vector, trabajamos con una recta; si tiene 2, con un plano; si tiene 3 con un espacio tridimensional, etc
- $0 \leq \dim(L) \leq \dim(\mathcal{V})$ , por lo tanto:
  - $\dim(L) = 0 \Leftrightarrow L = \{\emptyset\}$
  - $\dim(L) = \dim(\mathcal{V}) \Leftrightarrow L = \mathcal{V}$

#### 4.2.1. Ecuaciones de Base

Existen distintas formas de representar los vectores de una base  $\mathcal{B}$  en una variedad lineal  $L$ :

1. **Ecuación Vectorial:**  $x_{\mathcal{B}} = \sum_{i=1}^n \alpha_i v_{i\mathcal{B}}$
2. **Ecuación Paramétrica:** Es el sistema de ecuaciones que obtenemos.
3. **Ecuaciones Implícitas:** Expresandose como un sistema de ecuaciones o imponiendo que el número de ecuaciones sea igual a  $\dim(\mathcal{V}) = \dim(\mathcal{L})$ , es decir,  $\text{Rango}(u_{1\mathcal{B}} | \cdots | u_{n\mathcal{B}}) = \text{Rango}(u_{1\mathcal{B}} | \cdots | u_{n\mathcal{B}}|_{x_{\mathcal{B}}})$

$$\begin{pmatrix} x \\ y \\ z \end{pmatrix} = \alpha_1 \begin{pmatrix} 1 \\ 0 \\ -2 \end{pmatrix} + \alpha_2 \begin{pmatrix} 0 \\ -1 \\ 3 \end{pmatrix} \rightarrow_{1,2} \begin{cases} x = \alpha_1 \\ y = \alpha_2 \\ z = 3\alpha_2 - 2\alpha_1 \end{cases} \rightarrow_{2,3} 2x + 3y + z = 0$$

Ejemplo:

$$\mathcal{B} = \{v_1, \dots, v_5\} \quad L = \mathcal{L}\langle u_1, \dots, u_4 \rangle$$

$$\begin{cases} u_1 = v_1 - v_2 + 2v_3 + v_4 \\ u_2 = v_2 - 2v_3 + v_4 + 2v_5 \\ u_3 = v_2 + 6v_3 + 3v_4 - 4v_5 \\ u_4 = -v_1 + 2v_2 + v_4 - v_5 \end{cases} \Rightarrow \begin{cases} u_1(1, -1, 2, 1, 0) \\ u_2(0, 1, -2, 1, 2) \\ u_3(0, 1, 6, 3, -4) \\ u_4(-1, 2, 0, 1, -1) \end{cases}$$

Si queremos obtener una base de  $L$  en  $B$ , debemos sacar las ecuaciones implícitas de  $L$  en base  $B$ , por lo que el rango entre los vectores de  $L$  y los de  $L \cup \{x_{\mathcal{B}}\}$  deben de ser iguales:

$$\left( \begin{array}{cccc|c} 1 & 0 & 0 & -1 & x_1 \\ -1 & 1 & 1 & 2 & x_2 \\ 2 & -2 & 6 & 0 & x_3 \\ 1 & 1 & 3 & 1 & x_4 \\ 0 & 2 & -4 & -1 & x_5 \end{array} \right) \xrightarrow[\text{Usando Gauss}]{\text{Hacemos transformaciones elementales}} \left( \begin{array}{cccc|c} 1 & 0 & 0 & -1 & x_1 \\ 0 & 1 & 1 & 1 & x_1 + x_2 \\ 0 & 0 & 2 & 1 & -2x_1 - x_2 + x_4 \\ 0 & 0 & 0 & 0 & 8x_1 + 6x_2 + x_3 - 4x_4 \\ 0 & 0 & 0 & 0 & -8x_1 - 5x_2 - 3x_4 + x_5 \end{array} \right)$$

Vemos que el rango de  $L$  es 3, por lo que para que el rango de la matriz ampliada se iguale, obtenemos las ecuaciones de  $L$  en base  $\mathcal{B}$ :

$$\begin{cases} 8x_1 + 6x_2 + x_3 - 4x_4 = 0 \\ -8x_1 - 5x_2 - 3x_4 + x_5 = 0 \end{cases}$$



Por otro lado debemos de convertir la matriz escalonada que obtuvimos antes, a una diagonal unitaria, para así obtener una base de  $L$ , y como sabemos que el rango debe de ser 3, solo tendrá 3 variables esta base:

$$\begin{pmatrix} 1 & 0 & 0 & -1 \\ 0 & 1 & 0 & \frac{1}{2} \\ 0 & 0 & 1 & \frac{1}{2} \\ 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 \end{pmatrix} \equiv \left\{ \hat{u}_1, \hat{u}_2, \hat{u}_3, -\hat{u}_1 + \frac{1}{2}(\hat{u}_2 + \hat{u}_3) \right\}$$

### 4.3. Operaciones entre Espacios

### 4.4. Producto Escalar

#### 4.4.1. Ortogonalidad

### 4.5. Ortonormalidad

#### 4.5.1. Ortonormalidad de Gram–Schmidt

## 5. Tema 5: Aplicaciones Lineales y Diagonalización

## 6. Tema 6: Problema de Mínimos Cuadrados